



UNIVERSIDADE FEDERAL DO AMAZONAS
PROGRAMA DE PÓS GRADUAÇÃO EM ENGENHARIA ELÉTRICA

DECOMPOSIÇÃO EM VALORES SIGULARES

Andevaldo da Encarnação Vitório

MANAUS-AM

2024

Andeivaldo da Encarnação Vitório

DECOMPOSIÇÃO EM VALORES SIGULARES

Este trabalho foi preparado como parte dos requisitos da disciplina *Sistemas Lineares* oferecida pelo Programa de Pós-graduação em Engenharia Elétrica da Universidade Federal do Amazonas.

Prof. Dr. João Edgar Chaves Filho

MANAUS-AM

2024

Sumário

1	Introdução	3
2	Decomposição em Valores Singulares	4
2.1	Fundamentos Matemáticos	4
2.1.1	Construção das Matrizes	4
2.2	Aplicações em Processamento de Imagens	5
2.2.1	Compressão de Imagens	5
2.3	Exemplo Prático	6
3	Conclusão	9
A	Algoritmos Implementados	10

Capítulo I

Introdução

A decomposição em valores singulares (SVD, do inglês *Singular Value Decomposition*) é uma das técnicas mais poderosas e versáteis em álgebra linear, com ampla aplicação em diversas áreas da matemática, ciência e engenharia. Ela proporciona uma maneira eficiente de analisar e entender as propriedades de matrizes, seja em problemas de análise de dados, processamento de sinais, ou modelagem matemática. Ao decompor uma matriz em três componentes — uma matriz ortogonal U , uma matriz diagonal Σ , e uma matriz ortogonal transposta V^T — a SVD revela informações cruciais sobre a estrutura da matriz, como sua dimensionalidade, dependências lineares e comportamento sob transformações lineares.

Além de sua importância teórica, a SVD possui um grande número de aplicações práticas. Ela é essencial para a resolução de sistemas lineares, a compressão de dados, a aproximação de matrizes, e é amplamente utilizada em áreas como estatística e aprendizado de máquina. O poder da SVD reside na sua capacidade de simplificar problemas complexos, fornecendo representações compactas e mais compreensíveis de grandes volumes de dados.

Este trabalho explora a teoria e as aplicações da decomposição em valores singulares, destacando sua importância para a compreensão e manipulação de matrizes em uma variedade de contextos práticos. Através de exemplos, como a compressão de imagens, ilustramos o impacto da SVD na simplificação e otimização de processos computacionais.

Capítulo 2

Decomposição em Valores Singulares

A SVD é uma técnica fundamental em álgebra linear com aplicações em diversas áreas, como compressão de dados, processamento de imagens e solução de sistemas lineares. Este capítulo explora a utilização da SVD para fatoração e aproximação de matrizes grandes, com foco em imagens como caso prático.

2.1 Fundamentos Matemáticos

Seja A uma matriz de dimensões $m \times n$. A SVD permite escrever A como o produto de três matrizes:

$$A = USV^T, \quad (2.1)$$

onde U é uma matriz ortogonal de dimensão $m \times m$, cujas colunas são os vetores singulares à esquerda; S é uma matriz diagonal de dimensão $m \times n$, contendo os valores singulares $\sigma_1, \sigma_2, \dots, \sigma_r$ na diagonal, ordenados de forma decrescente ($\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$), sendo r o posto de A ; e V é uma matriz ortogonal de dimensão $n \times n$, cujas colunas são os vetores singulares à direita.

A decomposição é possível para qualquer matriz A , sem restrições de simetria ou de outros critérios. Isso distingue a SVD de outras técnicas de fatoração, como a diagonalização, que exige que a matriz seja quadrada e simétrica.

2.1.1 Construção das Matrizes

A matriz S contém os valores singulares de A , que estão relacionados com as raízes quadradas dos autovalores das matrizes $A^T A$ e AA^T . Esses valores medem a importância das diferentes dimensões em A e desempenham papel central em aplicações de compressão e aproximação. As colunas de U e

V são os vetores próprios de AA^\top e $A^\top A$, respectivamente. Esses vetores definem bases ortonormais no domínio e na imagem da transformação linear associada a A .

No processo de cálculo da SVD, primeiramente determina-se V multiplicando A por sua transposta A^\top , resultando na matriz simétrica $A^\top A$:

$$A^\top A = VS^2V^\top. \quad (2.2)$$

Diagonalizando $A^\top A$, os autovetores obtidos formam as colunas de V , enquanto os autovalores são os quadrados dos valores singulares.

Em seguida, determina-se U de forma similar a matriz V . Neste caso, calcula-se AA^\top , que também é simétrica:

$$AA^\top = US^2U^\top. \quad (2.3)$$

Os autovetores dessa matriz correspondem às colunas de U .

Por fim, a matriz S é construída posicionando os valores singulares na diagonal principal, com as demais entradas iguais a zero.

2.2 Aplicações em Processamento de Imagens

A SVD é amplamente utilizada para compressão de imagens. Ao representar uma imagem como uma matriz de intensidades, os valores singulares maiores capturam a maior parte da informação visual. Assim, pode-se aproximar a matriz original com poucos valores singulares, reduzindo o espaço de armazenamento sem perda significativa de qualidade visual.

2.2.1 Compressão de Imagens

A compressão de imagens utilizando a SVD baseia-se na transformação de uma matriz A , que representa a imagem, no formato $A = USV^\top$. O objetivo principal dessa transformação é reduzir o número de entradas necessárias para representar a matriz A sem comprometer significativamente a qualidade da informação.

Ao decompor A no produto USV^\top , é possível aproximar A utilizando uma versão de posto reduzido. Em termos práticos, essa redução remove informações redundantes, ou seja, aquelas que são linearmente dependentes. Assim, para um posto r menor que m ou n (as dimensões da matriz A), obtém-se uma matriz que captura a maior parte da essência estrutural de A , minimizando a perda de

informação relevante.

A matriz A pode ser reescrita como uma soma dos produtos externos escalados pelos valores singulares:

$$A = \sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \cdots + \sigma_r u_r v_r^\top + \sum_{i=r+1}^p \sigma_i u_i v_i^\top,$$

onde σ_i são os valores singulares ordenados em ordem decrescente ($\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$) e u_i, v_i são os vetores singulares à esquerda e à direita, respectivamente.

Os valores singulares associados a índices maiores que o posto r são iguais a zero. Consequentemente, os termos correspondentes não contribuem para a matriz A e podem ser ignorados, resultando na seguinte aproximação:

$$A \approx \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

Além disso, mesmo os valores singulares menores (aqueles próximos a zero) podem ser desconsiderados para reduzir ainda mais o número de termos na soma. Como os valores singulares são dispostos em ordem decrescente, os termos associados a valores singulares menores têm impacto reduzido na estrutura geral de A .

Ao descartar termos associados a valores singulares menores, a quantidade de dados necessária para representar a imagem é reduzida significativamente. Essa redução ocorre porque, em vez de armazenar todos os $m \times n$ elementos de A , armazenamos apenas os vetores singulares (u_i e v_i) e os valores singulares (σ_i) para $i \leq k$, onde k é o número de termos retidos. Além disso, a precisão da aproximação pode ser ajustada variando k . Retendo mais termos (k maior), preserva-se mais detalhes da imagem; ao reduzir k , a compressão é maior, mas pode haver perda de qualidade.

2.3 Exemplo Prático

Para ilustrar o processo de compressão de imagens utilizando a SVD, considera-se uma imagem, apresentada na Figura 2.1, representada por uma matriz A . O objetivo é reduzir o posto da matriz A para obter versões aproximadas da imagem original, utilizando um número menor de valores singulares.

A matriz A foi fatorada no formato $A = USV^\top$. Em seguida, foram construídas aproximações de posto reduzido ao reter apenas os k maiores valores singulares e seus vetores singulares associados.



Figura 2.1: Imagem original a ser comprimida.

Cada aproximação pode ser expressa como:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T, \quad (2.4)$$

onde k é o posto escolhido.

As imagens apresentadas na Figura 2.2 ilustram os resultados da compressão para diferentes valores de posto k , obtidas por meio do algoritmo implementado apresentado em Código A.1. Utilizando apenas os cinco maiores valores singulares ($k = 5$), observa-se que a estrutura geral da imagem é visível, embora com perda significativa de detalhes. Quando o número de termos é aumentado para $k = 20$, os contornos e formas tornam-se mais definidos. Com $k = 50$, a imagem apresenta maior nitidez e detalhes perceptíveis, aproximando-se da qualidade do original. Finalmente, ao utilizar $k = 100$, a imagem se aproxima ainda mais da original, com uma perda mínima de qualidade. Esses resultados demonstram que os primeiros valores singulares capturam a maior parte das informações relevantes da imagem, permitindo que uma retenção reduzida de termos seja suficiente para reconstruir uma aproximação de boa qualidade, ao mesmo tempo em que reduz significativamente o espaço necessário para armazenamento.

Do ponto de vista da eficiência, a compressão oferece uma redução considerável na complexidade de armazenamento. Enquanto a imagem original, de posto completo, exige o armazenamento de $m \times n$ entradas, uma aproximação de posto k requer apenas $k(m + n + 1)$ entradas, devido ao armazenamento das colunas de U_k , V_k^T e dos valores σ_i .




Figura 2.2: Resultados obtidos na compressão da imagem para postos iguais a 5, 20, 50 e 100.

Capítulo 3

Conclusão

A SVD é uma ferramenta fundamental em álgebra linear, amplamente utilizada para analisar e manipular matrizes em diversas aplicações práticas. Ao fatorar uma matriz A em três componentes — U , Σ e V^T —, a SVD permite interpretar as propriedades intrínsecas da matriz, como sua dimensão efetiva, dependência linear entre linhas e colunas e comportamento em transformações lineares.

O exemplo da compressão de imagens ilustra de forma prática a capacidade da SVD de capturar as informações mais relevantes de uma matriz ao reter apenas os maiores valores singulares. No entanto, suas aplicações vão muito além, abrangendo desde a solução de sistemas lineares e aproximações de matrizes até a análise de dados em estatística e aprendizado de máquina. A capacidade de reduzir matrizes complexas a formas simplificadas e interpretáveis torna a SVD uma ferramenta indispensável em áreas como processamento de sinais e reconhecimento de padrões.

Além disso, a SVD destaca-se por sua robustez, permitindo lidar com matrizes retangulares e mal-condicionadas, oferecendo uma base teórica sólida para resolver problemas de otimização e análise de estabilidade. Assim, a decomposição em valores singulares não apenas exemplifica a versatilidade da álgebra linear, mas também consolida seu papel essencial na ciência e na engenharia modernas.

Apêndice A

Algoritmos Implementados

O código a seguir realiza a compressão de imagens utilizando a linguagem *Python* e os seus pacotes *numpy* e *matplotlib*.

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  from matplotlib.image import imread
4
5  def compress_image(image, k):
6      """
7      Aplica a decomposição SVD e retorna a imagem reconstruída com rank k.
8      :param image: Matriz representando a imagem (grayscale ou canal de cor)
9      :param k: Número de componentes a serem mantidos.
10     :return: Imagem reconstruída com rank k.
11     """
12     U, S, Vt = np.linalg.svd(image, full_matrices=False)
13     S_k = np.diag(S[:k]) # Reduz os valores singulares para os k primeiros
14     return U[:, :k] @ S_k @ Vt[:, :]
15
16
17 # Carregar imagem em escala de cinza
18 image = imread("image.jpeg") # Caminho da imagem
19 if image.ndim == 3: # Converte para escala de cinza, se necessário
20     image = np.mean(image, axis=2)
21
22 # Parâmetros de compressão
23 ranks = [5, 20, 50, 100] # Níveis de compressão (postos)
24 fig, axs = plt.subplots(2, 2, figsize=(10, 10))
25
26 # Aplicar compressão e exibir resultados
27 for i, k in enumerate(ranks):
28     row, col = divmod(i, 2)
29     compressed_image = compress_image(image, k)
```

```
30     axs[row, col].imshow(compressed_image, cmap='gray')
31     axs[row, col].set_title(f"Posto {k}")
32     axs[row, col].axis('off')
33
34 plt.tight_layout()
35 plt.show()
```

Código A.1: Implementação do algoritmo de compressão de imagens usando SVD.