



**UNIVERSIDADE FEDERAL DO AMAZONAS**  
**PROGRAMA DE PÓS GRADUAÇÃO EM ENGENHARIA ELÉTRICA**

**DECOMPOSIÇÃO EM VALORES SIGULARES**

**Andeivaldo da Encarnação Vitório**

**MANAUS-AM**

**2024**



Andeivaldo da Encarnação Vitório

## DECOMPOSIÇÃO EM VALORES SIGULARES

Este trabalho foi preparado como parte dos requisitos da disciplina *Sistemas Lineares* oferecida pelo Programa de Pós-graduação em Engenharia Elétrica da Universidade Federal do Amazonas.

Prof. Dr. João Edgar Chaves Filho

MANAUS-AM

2024



# Sumário

<b>1</b>	<b>Introdução</b>	<b>7</b>
<b>2</b>	<b>Decomposição em Valores Singulares</b>	<b>9</b>
2.1	Fundamentos Matemáticos . . . . .	9
2.1.1	Construção das Matrizes . . . . .	9
2.2	Aplicações em Processamento de Imagens . . . . .	10
2.2.1	Compressão de Imagens . . . . .	10
2.3	Exemplo Prático . . . . .	11
<b>3</b>	<b>Conclusão</b>	<b>15</b>
<b>A</b>	<b>Algoritmos Implementados</b>	<b>17</b>



# Capítulo I

## Introdução

A decomposição em valores singulares (SVD, do inglês *Singular Value Decomposition*) é uma das técnicas mais poderosas e versáteis em álgebra linear, com ampla aplicação em diversas áreas da matemática, ciência e engenharia. Ela proporciona uma maneira eficiente de analisar e entender as propriedades de matrizes, seja em problemas de análise de dados, processamento de sinais, ou modelagem matemática. Ao decompor uma matriz em três componentes — uma matriz ortogonal  $U$ , uma matriz diagonal  $\Sigma$ , e uma matriz ortogonal transposta  $V^T$  — a SVD revela informações cruciais sobre a estrutura da matriz, como sua dimensionalidade, dependências lineares e comportamento sob transformações lineares.

Além de sua importância teórica, a SVD possui um grande número de aplicações práticas. Ela é essencial para a resolução de sistemas lineares, a compressão de dados, a aproximação de matrizes, e é amplamente utilizada em áreas como estatística e aprendizado de máquina. O poder da SVD reside na sua capacidade de simplificar problemas complexos, fornecendo representações compactas e mais compreensíveis de grandes volumes de dados.

Este trabalho explora a teoria e as aplicações da decomposição em valores singulares, destacando sua importância para a compreensão e manipulação de matrizes em uma variedade de contextos práticos. Através de exemplos, como a compressão de imagens, ilustramos o impacto da SVD na simplificação e otimização de processos computacionais.





## Capítulo 2

# Decomposição em Valores Singulares

A SVD é uma técnica fundamental em álgebra linear com aplicações em diversas áreas, como compressão de dados, processamento de imagens e solução de sistemas lineares. Este capítulo explora a utilização da SVD para fatoração e aproximação de matrizes grandes, com foco em imagens como caso prático.

### 2.1 Fundamentos Matemáticos

Seja  $A$  uma matriz de dimensões  $m \times n$ . A SVD permite escrever  $A$  como o produto de três matrizes:

$$A = USV^T, \quad (2.1)$$

onde  $U$  é uma matriz ortogonal de dimensão  $m \times m$ , cujas colunas são os vetores singulares à esquerda;  $S$  é uma matriz diagonal de dimensão  $m \times n$ , contendo os valores singulares  $\sigma_1, \sigma_2, \dots, \sigma_r$  na diagonal, ordenados de forma decrescente ( $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ ), sendo  $r$  o posto de  $A$ ; e  $V$  é uma matriz ortogonal de dimensão  $n \times n$ , cujas colunas são os vetores singulares à direita.

A decomposição é possível para qualquer matriz  $A$ , sem restrições de simetria ou de outros critérios. Isso distingue a SVD de outras técnicas de fatoração, como a diagonalização, que exige que a matriz seja quadrada e simétrica.

#### 2.1.1 Construção das Matrizes

A matriz  $S$  contém os valores singulares de  $A$ , que estão relacionados com as raízes quadradas dos autovalores das matrizes  $A^T A$  e  $AA^T$ . Esses valores medem a importância das diferentes dimensões em  $A$  e desempenham papel central em aplicações de compressão e aproximação. As colunas de  $U$  e

$V$  são os vetores próprios de  $AA^\top$  e  $A^\top A$ , respectivamente. Esses vetores definem bases ortonormais no domínio e na imagem da transformação linear associada a  $A$ .

No processo de cálculo da SVD, primeiramente determina-se  $V$  multiplicando  $A$  por sua transposta  $A^\top$ , resultando na matriz simétrica  $A^\top A$ :

$$A^\top A = VS^2V^\top. \quad (2.2)$$

Diagonalizando  $A^\top A$ , os autovetores obtidos formam as colunas de  $V$ , enquanto os autovalores são os quadrados dos valores singulares.

Em seguida, determina-se  $U$  de forma similar a matriz  $V$ . Neste caso, calcula-se  $AA^\top$ , que também é simétrica:

$$AA^\top = US^2U^\top. \quad (2.3)$$

Os autovetores dessa matriz correspondem às colunas de  $U$ .

Por fim, a matriz  $S$  é construída posicionando os valores singulares na diagonal principal, com as demais entradas iguais a zero.

## 2.2 Aplicações em Processamento de Imagens

A SVD é amplamente utilizada para compressão de imagens. Ao representar uma imagem como uma matriz de intensidades, os valores singulares maiores capturam a maior parte da informação visual. Assim, pode-se aproximar a matriz original com poucos valores singulares, reduzindo o espaço de armazenamento sem perda significativa de qualidade visual.

### 2.2.1 Compressão de Imagens

A compressão de imagens utilizando a SVD baseia-se na transformação de uma matriz  $A$ , que representa a imagem, no formato  $A = USV^\top$ . O objetivo principal dessa transformação é reduzir o número de entradas necessárias para representar a matriz  $A$  sem comprometer significativamente a qualidade da informação.

Ao decompor  $A$  no produto  $USV^\top$ , é possível aproximar  $A$  utilizando uma versão de posto reduzido. Em termos práticos, essa redução remove informações redundantes, ou seja, aquelas que são linearmente dependentes. Assim, para um posto  $r$  menor que  $m$  ou  $n$  (as dimensões da matriz  $A$ ), obtém-se uma matriz que captura a maior parte da essência estrutural de  $A$ , minimizando a perda de

informação relevante.

A matriz  $A$  pode ser reescrita como uma soma dos produtos externos escalados pelos valores singulares:

$$A = \sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \cdots + \sigma_r u_r v_r^\top + \sum_{i=r+1}^p \sigma_i u_i v_i^\top,$$

onde  $\sigma_i$  são os valores singulares ordenados em ordem decrescente ( $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ ) e  $u_i, v_i$  são os vetores singulares à esquerda e à direita, respectivamente.

Os valores singulares associados a índices maiores que o posto  $r$  são iguais a zero. Consequentemente, os termos correspondentes não contribuem para a matriz  $A$  e podem ser ignorados, resultando na seguinte aproximação:

$$A \approx \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

Além disso, mesmo os valores singulares menores (aqueles próximos a zero) podem ser desprezados para reduzir ainda mais o número de termos na soma. Como os valores singulares são dispostos em ordem decrescente, os termos associados a valores singulares menores têm impacto reduzido na estrutura geral de  $A$ .

Ao descartar termos associados a valores singulares menores, a quantidade de dados necessária para representar a imagem é reduzida significativamente. Essa redução ocorre porque, em vez de armazenar todos os  $m \times n$  elementos de  $A$ , armazenamos apenas os vetores singulares ( $u_i$  e  $v_i$ ) e os valores singulares ( $\sigma_i$ ) para  $i \leq k$ , onde  $k$  é o número de termos retidos. Além disso, a precisão da aproximação pode ser ajustada variando  $k$ . Retendo mais termos ( $k$  maior), preserva-se mais detalhes da imagem; ao reduzir  $k$ , a compressão é maior, mas pode haver perda de qualidade.

## 2.3 Exemplo Prático

Para ilustrar o processo de compressão de imagens utilizando a SVD, considera-se uma imagem, apresentada na Figura 2.1, representada por uma matriz  $A$ . O objetivo é reduzir o posto da matriz  $A$  para obter versões aproximadas da imagem original, utilizando um número menor de valores singulares.

A matriz  $A$  foi fatorada no formato  $A = USV^\top$ . Em seguida, foram construídas aproximações de posto reduzido ao reter apenas os  $k$  maiores valores singulares e seus vetores singulares associados.



Figura 2.1: Imagem original a ser comprimida.

Cada aproximação pode ser expressa como:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T, \quad (2.4)$$

onde  $k$  é o posto escolhido.

As imagens apresentadas na Figura 2.2 ilustram os resultados da compressão para diferentes valores de posto  $k$ , obtidas por meio do algoritmo implementado apresentado em Código A.1. Utilizando apenas os cinco maiores valores singulares ( $k = 5$ ), observa-se que a estrutura geral da imagem é visível, embora com perda significativa de detalhes. Quando o número de termos é aumentado para  $k = 20$ , os contornos e formas tornam-se mais definidos. Com  $k = 50$ , a imagem apresenta maior nitidez e detalhes perceptíveis, aproximando-se da qualidade do original. Finalmente, ao utilizar  $k = 100$ , a imagem se aproxima ainda mais da original, com uma perda mínima de qualidade. Esses resultados demonstram que os primeiros valores singulares capturam a maior parte das informações relevantes da imagem, permitindo que uma retenção reduzida de termos seja suficiente para reconstruir uma aproximação de boa qualidade, ao mesmo tempo em que reduz significativamente o espaço necessário para armazenamento.

Do ponto de vista da eficiência, a compressão oferece uma redução considerável na complexidade de armazenamento. Enquanto a imagem original, de posto completo, exige o armazenamento de  $m \times n$  entradas, uma aproximação de posto  $k$  requer apenas  $k(m + n + 1)$  entradas, devido ao armazenamento das colunas de  $U_k$ ,  $V_k^T$  e dos valores  $\sigma_i$ .




Figura 2.2: Resultados obtidos na compressão da imagem para postos iguais a 5, 20, 50 e 100.



## Capítulo 3

### Conclusão

A SVD é uma ferramenta fundamental em álgebra linear, amplamente utilizada para analisar e manipular matrizes em diversas aplicações práticas. Ao fatorar uma matriz  $A$  em três componentes —  $U$ ,  $\Sigma$  e  $V^T$  —, a SVD permite interpretar as propriedades intrínsecas da matriz, como sua dimensão efetiva, dependência linear entre linhas e colunas e comportamento em transformações lineares.

O exemplo da compressão de imagens ilustra de forma prática a capacidade da SVD de capturar as informações mais relevantes de uma matriz ao reter apenas os maiores valores singulares. No entanto, suas aplicações vão muito além, abrangendo desde a solução de sistemas lineares e aproximações de matrizes até a análise de dados em estatística e aprendizado de máquina. A capacidade de reduzir matrizes complexas a formas simplificadas e interpretáveis torna a SVD uma ferramenta indispensável em áreas como processamento de sinais e reconhecimento de padrões.

Além disso, a SVD destaca-se por sua robustez, permitindo lidar com matrizes retangulares e mal-condicionadas, oferecendo uma base teórica sólida para resolver problemas de otimização e análise de estabilidade. Assim, a decomposição em valores singulares não apenas exemplifica a versatilidade da álgebra linear, mas também consolida seu papel essencial na ciência e na engenharia modernas.





# Apêndice A

## Algoritmos Implementados

O código a seguir realiza a compressão de imagens utilizando a linguagem *Python* e os seus pacotes *numpy* e *matplotlib*.

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  from matplotlib.image import imread
4
5  def compress_image(image, k):
6      """
7      Aplica a decomposição SVD e retorna a imagem reconstruída com rank k.
8      :param image: Matriz representando a imagem (grayscale ou canal de cor)
9      :param k: Número de componentes a serem mantidos.
10     :return: Imagem reconstruída com rank k.
11     """
12     U, S, Vt = np.linalg.svd(image, full_matrices=False)
13     S_k = np.diag(S[:k]) # Reduz os valores singulares para os k primeiros
14     return U[:, :k] @ S_k @ Vt[:k, :]
15
16
17 # Carregar imagem em escala de cinza
18 image = imread("image.jpeg") # Caminho da imagem
19 if image.ndim == 3: # Converte para escala de cinza, se necessário
20     image = np.mean(image, axis=2)
21
22 # Parâmetros de compressão
23 ranks = [5, 20, 50, 100] # Níveis de compressão (postos)
24 fig, axs = plt.subplots(2, 2, figsize=(10, 10))
25
26 # Aplicar compressão e exibir resultados
27 for i, k in enumerate(ranks):
28     row, col = divmod(i, 2)
29     compressed_image = compress_image(image, k)
```

```
30     axs[row, col].imshow(compressed_image, cmap='gray')
31     axs[row, col].set_title(f"Posto {k}")
32     axs[row, col].axis('off')
33
34 plt.tight_layout()
35 plt.show()
```

Código A.1: Implementação do algoritmo de compressão de imagens usando SVD.